



兰州大学

本科毕业论文（设计）

论文题目（中文） 深度学习与医学超声图像分割应用

论文题目（英文） Deep Learning and Medical Ultrasound
Image Segmentation Applications

学 生 姓 名 刘伟鹏

导师姓名、职称 马义德 教授

学生所属学院 信息科学与工程学院

专 业 计算机科学与技术（数据科学方向）

年 级 2019 级

诚信责任书

本人郑重声明：本人所呈交的毕业论文（设计），是在导师的指导下独立进行研究所取得的成果。毕业论文（设计）中凡引用他人已经发表或未发表的成果、数据、观点等，均已明确注明出处。除文中已经注明引用的内容外，不包含任何其他个人或集体已经发表或在网上发表的论文。

本声明的法律责任由本人承担。

论文作者签名：_____

日 期：_____

关于毕业论文（设计）使用授权的声明

本人在导师指导下所完成的论文及相关的职务作品，知识产权归属兰州大学。本人完全了解兰州大学有关保存、使用毕业论文的规定，同意学校保存或向国家有关部门或机构送交论文的纸质版和电子版，允许论文被查阅和借阅；本人授权兰州大学可以将本毕业论文的全部或部分内 容编入有关数据库进行检索，可以采用任何复制手段保存和汇编本毕业论文。本人离校后发表、使用毕业论文或与该论文直接相关的学术论文或成果时，第一署名单位仍然为兰州大学。

本毕业论文研究内容：

☐可以公开

☐不宜公开，已在学位办公室办理保密申请，解密后适用本授权书。

（请在以上选项内选择其中一项打“√”）

论文作者签名：_____

导师签名：_____

日 期：_____

日 期：_____

深度学习与医学超声图像分割应用

中文摘要

超声图像是当前医学领域中最主要的成像手段之一。超声是近年来快速发展的一种可实时显像的技术，拥有非常多的优点，但同时也存在着成像质量差等不足。目前超声图像主要由专业医生进行人工阅片，然而，由于医生的主观因素等原因，人工阅片有时会出现诊断水平不一致的情况。为了解决这类问题，计算机辅助诊断系统（CAD）往往会为医生提供帮助，提高疾病的诊断速度和医生的工作效率。利用深度学习实现医学超声图像分割，是计算机辅助诊断系统中的一个重要组成部分。深度学习以其自动提取特征的能力和强大的泛用性，能够在医学图像分割任务中取得不错的效果，有着非常重要的研究价值和应用前景。

本文将重点关注 ACU-Net（Atrous Convolution U-Net）模型，该模型通过对经典 U-Net 网络结构进行改进，加入 ASPP 模块、注意力模块并对激活函数进行替换，从而提高分割性能。实验采用医学超声图像中较有代表性的乳腺超声图像，利用 ACU-Net 模型对乳腺癌区域进行分割，并评估其性能。本文主要完成的工作如下：

- （1）对 BUSI 数据集进行预处理，并针对其数据集不足的情况进行数据增强，通过旋转和翻转等方法扩充数据集。
- （2）利用 U-Net 模型和 ACU-Net 模型对数据集完成分割任务，以四种指标进行性能评估，并通过消融实验验证 Frelu（Flexible ReLU）激活函数和 SE-Net（Squeeze-and-Excitation Networks）注意力模块对于 ACU-Net 分割性能所带来的提升。
- （3）通过对比 12 组 ACU-Net 在不同膨胀率下的分割性能表现，找出 3 个最佳的膨胀系数，并得到最佳分割模型。

关键词：深度学习、超声图像、图像分割、编码器-解码器结构

Deep Learning and Medical Ultrasound Image Segmentation Applications

Abstract

Ultrasound images are one of the most important imaging tools in the current medical field. Ultrasound is a rapidly developing technology that allows real-time imaging in recent years and has many advantages, but also has shortcomings such as poor imaging quality. At present, ultrasound images are mainly read manually by specialized physicians, however, due to subjective factors of physicians and other reasons, manual reading sometimes results in inconsistent diagnostic levels. To solve such problems, computer-aided diagnostic systems (CAD) often provide assistance to physicians, improving the speed of disease diagnosis and physician productivity. The use of deep learning for medical ultrasound image segmentation is an important part of CAD systems. With its ability to automatically extract features and powerful generalization, deep learning can achieve good results in medical image segmentation tasks and has very important research value and application prospects.

This paper will focus on the ACU-Net (Atrous Convolution U-Net) model, which improves the segmentation performance by improving the structure of the classical U-Net network, adding ASPP module, attention module and replacing the activation function. The experiments use breast ultrasound images, which are more representative of medical ultrasound images, to segment the breast cancer region using the ACU-Net model and evaluate its performance. The main work accomplished in this paper is as follows:

- (1) Pre-processing the BUSI dataset and data enhancement for its insufficient dataset, expanding the dataset by rotation and flipping, etc.
- (2) To perform the segmentation task on the dataset using the U-Net model and the ACU-Net model, and to evaluate the performance with four metrics, and to verify the performance of the Frelu (Flexible ReLU) activation function and the SE-Net (Squeeze-and-Excitation Networks) attention module on the ACU-Net by ablation experiments. The improvement brought by the partitioning performance.
- (3) By comparing the segmentation performance performance of 12 groups of ACU-Net under different expansion rates, three best expansion coefficients are identified and the best segmentation model is obtained.

Keywords: deep learning, ultrasound image, image segmentation, encoder-decoder architecture

目 录

中文摘要.....	I
英文摘要.....	II
第一章 绪论.....	1
1.1 课题研究背景及意义.....	1
1.2 国内外研究现状.....	2
第二章 深度学习模型.....	3
2.1 编码器-解码器 U 形分割模型（U-Net）.....	3
2.2 研究主要内容.....	4
2.2.1 空洞卷积.....	5
2.2.2 ASPP 模块.....	6
2.2.3 注意力模块.....	7
2.2.4 FReLU 激活函数.....	8
第三章 基于 ACU-Net 的医学超声图像分割.....	10
3.1 实验综述.....	10
3.2 实验数据集预处理.....	10
3.2.1 数据集介绍.....	10
3.2.2 数据集预处理.....	11
3.3 实验.....	12
3.3.1 实验简介.....	12
3.3.2 损失函数.....	12

3.3.3 评价指标.....	13
3.3.4 实验结果.....	14
第四章 总结与展望.....	17
4.1 全文总结	17
4.2 研究展望	17
参考文献.....	19
致 谢.....	20

第一章 绪论

1.1 课题研究背景及意义

近年来，由于生活习惯的改变和社会压力的增加，各种疾病也随之出现，给人们的生活与工作带来了很大的影响。据国际癌症调查研究机构（IARC）统计，北上广等一线城市肿瘤发病率与欧美等发达国家相当，且正在趋向年轻化，但具体机制尚不明确^[1]。在这一背景下，如何做到在早期进行筛查、发现和治疗，已显得尤为重要。

医生在诊断病人的时候，常常利用超声图像来判断患者的病情，这是由于超声具有无创、无辐射、高精度、低成本等优点，通过接收和处理超声声束反射信号，就能得到人体脏器的结构图像^[2]。然而，传统的人工检查图像方法耗时耗力，医生在使用超声图像对病情进行诊断时，由于缺乏经验或主观因素等原因，导致医生对超声图像的诊断水平不一致，甚至出现误诊现象，耽误患者病情。

在此情况下，亟需发展计算机辅助诊断系统（Computer Aided Diagnosis, CAD），以提高医生工作效率。CAD 是将计算机和医学两大领域相融合的一种新技术，它可以极大地提高疾病的诊断速度，减少医生主观因素的影响，并降低病人的医疗成本^[3]。与机器学习相比，深度学习可以在不依赖于人工的情况下，从图像中自动地提取出图像特征，也不要求研究者拥有丰富的医学知识，因此能够节约很多的人力和物力，可以很容易地运用到医学图像的分类中。目前，深度学习的成功已在很多领域得到了证实，尤其是在超声图像分割领域，与传统算法相比，深度学习算法取得了更加显著的效果。深度学习是一种具有多层网络模型的神经网络，通过下采样、权重共享等方法，可以有效地简化神经网络模型，减少计算量。如今，基于卷积神经网络的深度学习模型在医学图像的分类与分割中有着优异的表现，其识别准确率远高于传统人工识别方法，有望极大地降低医生的工作负荷^[4]。

随着最近几年人工智能领域的热度不断攀升，作为机器学习分支的深度学习得到了快速发展。深度学习凭借着强大的性能和端到端的便捷性等特点，被广泛地应用于计算机视觉领域、语音识别、文字识别和图像处理领域。目前，深度学习已经能被用于处理各式各样的复杂任务，在医学领域，它已逐渐成为计算机辅助诊断算法的主流。

利用深度学习实现医学超声图像的自动分割，是计算机辅助诊断系统中的一

个重要组成部分。深度学习强大的泛用能力使得它在各种类型成像上都能很好地完成任务。它可以处理医学超声图像并从中分割出对我们有用的目标，并从各个角度观察病灶和结构，让医生可以更准确地量化病灶的变化情况，并最终帮助医生做出决策。研究深度学习与医学超声图像分割应用，对现代医学具有重要的实用价值和前景^[5]。

1.2 国内外研究现状

深度学习属于人工智能领域中机器学习的一个分支，机器学习的核心思路是通过设计系统使其模仿人类的决策思维来解决各种问题，它又可细分为“监督式学习”和“非监督式学习”。神经网络架构是深度学习中应用最广泛的框架。在医学图像分割与分析的领域中，常见的深度神经网络架构有：卷积神经网络（CNN）、全卷积神经网络（FCN）、U-Net 网络结构等^[6]。

卷积神经网络作为最具代表性的深度学习框架，在图像分类与检测中得到了广泛的运用。卷积神经网络由一个或多个卷积层和顶端的全连通层组成，同时也包括关联权重和池化层。由于其具有对抽象特征学习的能力，对目标尺寸、位置、方向等不太敏感的特点，因此基于卷积神经网络的图像分类方法具有很高的识别性能。不过，因为某些细节的缺失，所以他们不能给出对象的具体轮廓，也无法表示出各个像素属于哪个对象。所以，要达到精确分割是非常困难的。

为了解决这个问题，全卷积网络应运而生。2015 年，UC Berkeley 和 Jonathan Long 等人提出的用于图像语义分割的一种新框架，并命名为全卷积网络（Fully Convolutional Networks, FCN）。全卷积网络由卷积神经网络改进得来，加入了上采样的过程，并引入跳级结构，对图像分割有精化作用。全卷积网络是对图像进行像素级分类的代表，也是语义分割的开山之作。全卷积网络的提出实现了端到端的分割，为图像分割开辟了新思路。然而，由于医学图像自身的复杂特性，其分割过程中存在着一系列的问题，如不均匀性、个体间的差异性等，传统的图像分割算法难以直接用于医学图像的分割。

同样是 2015 年，Philipp Fischer 等人首次在 Kaggle 挑战赛中使用了 U-net 网络，U-net 同样只有卷积层和池化层，在卷积池化之后也有上采样过程。U-net 和 FCN 的区别在于，U-net 的卷积与反卷积过程采用了相同数量层次的卷积操作，并且通过 skip-connection 结构连接了卷积池化层和反卷积层，这样从下采样中提取到的特征可以被直接传输到反卷积层，因此 U-net 的像素定位相对于 FCN 来说更为精确，分割的准确性也更高，这对医学图像分割这类对细节要求极高的任务来说尤为重要^[7]。

第二章 深度学习模型

2.1 编码器-解码器 U 形分割模型（U-Net）

基于 U-Net 的编码器-解码器分割模型,其特点为 U 型结构和跳层连接(skip-connection)。U-Net 采用跳层连接将深、浅特征图拼接在一起,这种跳变拼接既提供了浅层的局部信息进行上采样,又充分融合了深度信息,是提高像素连接和减少信息丢失的关键^[8]。

如图 2.1 所示, U-Net 网络分为左右两个部分,包含 4 组卷积层和 4 组上采样层,一般左侧为编码器,用来提取特征,右侧为解码器,用来上采样。

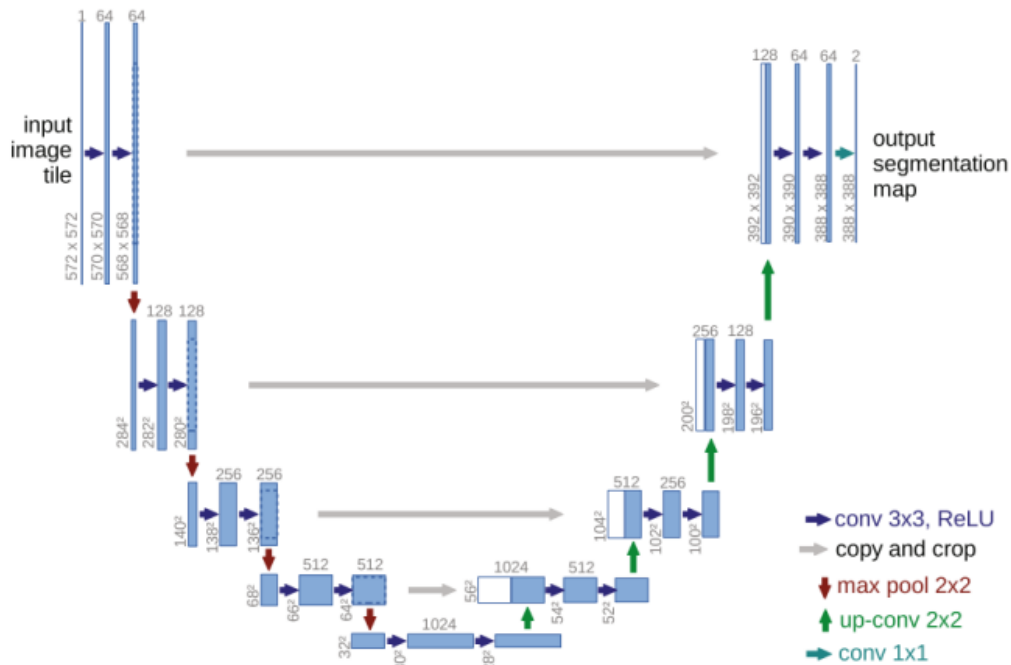


图 2.1 U-Net 网络

在左侧即编码器部分,每组卷积都是由两个卷积单元堆叠而成,每个单元都由 3×3 的卷积核进行卷积,由 2×2 的最大池化层对每两个卷积层进行连接,从而使得到的特征图尺寸比原来缩小一半,而特征层数不变。在完成了最后一组卷积后,进行池化所得到的特征图通过两次 3×3 的卷积送入到解码器部分中。

在右侧即解码器部分,每组卷积都由一个特征融合单元,两个堆叠的卷积单元和一个转置卷积组成。转置卷积单元输出特征层,跳跃连接传递特征图,将两者进行向量级别的连接,得到融合的特征层。该融合特征图再通过两个连续的卷积单元得到特征图,并再次通过转置卷积上采样得到特征图,此特征图尺寸与上

一层跳跃连接过来的特征图相同，将两者进行连接，每次转置卷积后特征图的尺寸增加一倍，层数缩小一半^[9]。

由于医学图像具有数据量较少的特点，而 U-Net 网络的跳跃连接结构结合了较多尺度，对于医学图像分割十分有效。

2.2 研究主要内容

本文将关注一个对 U-Net 进行改进的模型，即 ACU-Net 模型。ACU-Net 利用空洞卷积提高感受野和细节捕获能力，用轻量级的 ASPP 模块代替 U-Net 特征提取部分的两层连续卷积，保留原有 U-Net 结构的对称 U 型结构，并将 ASPP 模块的输出与上采样部分拼接，同时改进激活函数并增加注意力模块，使模型具有更好的性能，降低模型的训练难度，充分挖掘样本的隐藏信息，捕捉更有效的特征。

如图 2.2 所示，ACU-Net 模型采用两层 3×3 的卷积核捕获输入图像的基本特征，然后使用优化后的 ASPP 模块替换原 U-Net 网络下采样中的两层普通卷积，并使用步幅为 2 的 2×2 最大池化层连接前后两层，扩大每次下采样的感受野，使 U 底部最深的语义信息更足以包含更多的图像信息，从而在上采样过程中为特征输入提供更多的语义信息。在上采样过程中，ACU-Net 和 U-Net 的结构是相同的。每个下采样步骤由 2×2 卷积组成，该卷积将特征通道的数量减半，并重复应用两个 3×3 卷积。另外，利用视觉激活函数 FReLU 完全替代了 ReLU，每一层后面都有一个 FReLU，有效提高了像素对像素的建模能力^[10]。




图 2.2 ACU-Net 结构

2.2.1 空洞卷积

空洞卷积（**atrous convolutions**）是针对图像语义分割问题中下采样会降低图像分辨率、丢失信息而提出的一个卷积网络。利用添加空洞扩大感受野，能够让原本 3×3 的卷积核，在相同参数量核计算量下拥有 5×5 或者更大的感受野，并在增加感受野的同时保持特征图的尺寸不变，避免了精度上的损失。因此在特征图相同的情况下，采用空洞卷积可以得到更大的感受野，并获得更加密集的数据，而更大的感受野可以提高在目标检测和语义分割的任务中的小物体识别分割的效果。在图像识别分割任务中，当网络层需要更大的感受野，但是由于计算资源有限或其它原因无法提高卷积核数量或大小时，可以考虑使用空洞卷积。




图 2.3 普通卷积




图 2.4 空洞卷积

空洞卷积引入了一个称为“膨胀率（**dilated rate**）”的新参数，又称扩张率或空洞率。两个像素之间的距离，就是膨胀率。该参数定义了卷积核处理数据时各值的间距，也就是说相比原来的标准卷积，空洞卷积多了一个超参数（**hyper-parameter**）称之为膨胀率，指的是 **kernel** 各点之间的间隔数量。如图 2.5 所示，空洞卷积通过给卷积核插入“空洞”来变相地增加其大小。




图 2.5 “空洞”插入卷积核

2.2.2 ASPP 模块

空洞卷积具有扩展感受野和捕获全局语义信息的优点,但在实际使用中最大的问题是在相同膨胀率下得到的卷积结果之间没有联系。如果只重复叠加一个卷积膨胀率,会丢失大量的局部像素信息。所以如果不进行优化,训练时间和难度都会增加。为了解决此问题,该模型引入了 ASPP 模块。ASPP 模块由多个并行的空洞卷积层和一个全局池化层组成,用于增加卷积核的感受野和捕捉多尺度的特征,通过不同的膨胀率构建不同感受野的卷积核,用来获取多尺度物体信息。

ASPP 在捕获不同距离的全局关系和像素细节特征的同时,在同一特征图上以不同的膨胀率进行空洞卷积。然后将这些卷积结果拼接在一起,使用卷积核大小为 1×1 的二维卷积来恢复输入特征图的大小。基本 ASPP 的结构示意图如图 2.6 所示。




图 2.6 ASPP 结构示意图

根据 Chen 等人提出的 DeepLab-v3+模型中 ASPP 的条件^[11],为了平衡加入 ASPP 后 U-Net 的体积和性能,该模型采用的改进 ASPP 模块共包含三层:第一层为普通卷积层,卷积核为 3×3 ,膨胀率为 1;第二层保持卷积核的大小不变,将膨胀率改为 6;第三层将膨胀率改为 12。其结构图如图 2.7 所示。

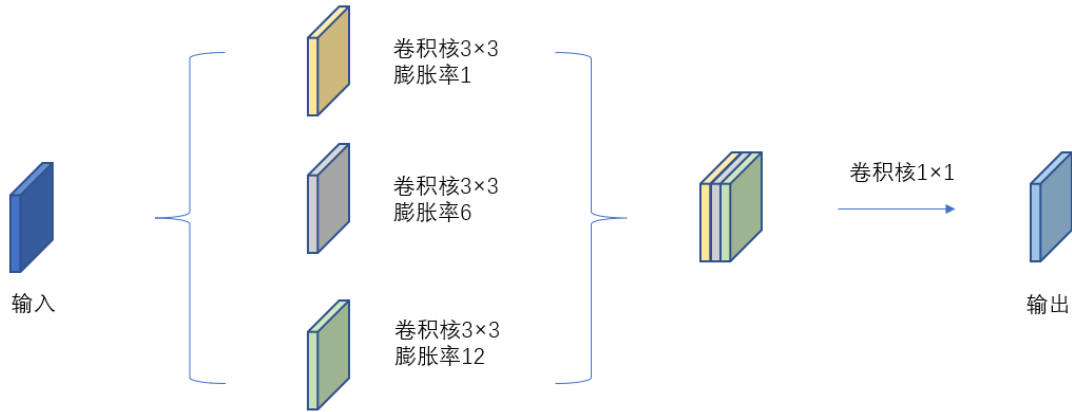


图 2.7 改进 ASPP 模块

2.2.3 注意力模块

除了 ASPP 模块之外，ACU-Net 模型还引入了注意力模块。注意力模块由于其即插即用的特点和能有效提高准确率特性，在卷积神经网络中得到了广泛的应用。在 Hu 提出注意机制鼻祖 SE-Net 之后，各种模块例如通道空间串行注意力模块 CBAM、并行注意力模块 BAM、以及非局部注意力模块等不断涌现。近年来，出现了更轻量级、更协调的注意力模块 CA-Net、ECA-Net 和基于自注意的双注意 DANet。

SE-Net 全称为 Squeeze-and-Excitation Networks，是从通道的角度来考虑，主要包含压缩（Squeeze）和激活（Excitation）两个操作。由于不同的卷积核刻画了信号的不同方面的特征，有些特征是重要的，而有些特征可以忽略，如何计算一个通道维度上的权重来对通道进行加权处理成为了 SE-Net 的核心。SE-Net 的目的是优化信道链路上的编码质量，通过压缩和扩展信道信息，提高整个网络的信息综合能力，增强特征层信道之间的内在联系，减少不必要的编码信息和链路。它能使网络在训练和使用过程中利用更多的信道信息，并对信息进行自适应调整。SE-Net 模块几乎可以连接到任何网络模型结构中，通过加权使得主要信息更加突出并抑制无用信息。其结构图如图 2.8 所示。




图 2.8 SE-Net 结构示意图

SE-Net 是对卷积结束后的部分作出了一些改进，这一部分是计算一个通道维度上的权重来对通道进行加权处理。该注意力模块通过对每个特征层进行平均池化操作，将 $H \times W \times C$ 的特征输入转换为 $1 \times 1 \times C$ 的特征再输出，再经过两个全连接层，最后通过 sigmoid 函数限制到 $[0, 1]$ 的范围，即前文所说的通道维度上的权重，把这个权重乘到刚刚卷积得到的 C 个通道上，作为下一层的输入。需要注意的是，第一个完全连接层(Squeeze)后面是 ReLU 而不是 FReLU，第二个完全连接层(Excitation)后面是 Sigmoid。然后，将完全连接层后的输出与原始特征相乘，得到注意力网络的最终结果。

ACU-Net 模型在 U 型结构的底部，即最后一次下采样和第一次上采样之间，增加了一个注意力模块，来提高模型感知环境和感受野的能力，同时降低模型的训练难度，进一步提高模型的效率。在 ACU-Net 中添加注意模块后的示意图如图 2.9 所示。




图 2.9 增加注意力模块后的 ACU-Net 结构

2.2.4 FReLU 激活函数

FReLU 全称为 Flexible ReLU，即柔性线性整流函数，是由旷视和香港科技大学在 ECCV2020 发表的一篇论文《Funnel Activation for Visual Recognition》中提出的^[12]。FReLU 是 ReLU 的全新变种，可以看做是整流函数和非线性函数的结合，具有更强的表示能力和更广泛的应用场景。FReLU 作为一种新兴的激活函数，具有较强的自适应能力和更广泛的应用场景。无论是在残差学习、批量归一化还是分布式学习场景中，FReLU 都具有独特的优势，可以为深度学习领域的研究和应用带来新的可能性和前景。

ReLU 函数计算量小，收敛速度快，但在训练反向传播过程中也存在信息丢失和数据更新困难的问题。为了解决这些问题，FReLU 函数针对所有负输入为零的神经元消失问题进行了优化，通过增加了微不足道的空间条件开销，将 ReLU 和 PReLU 扩展为二维激活函数。此外，空间条件以简单的方式实现像素级的建

模能力，通过规则的卷积捕获复杂的视觉布局，极大提高了在视觉识别任务上的性能。FReLU 激活函数的公式为：

$$\text{FReLU}(x) = \text{MAX}(T(x), x) \quad (2-1)$$

其中 x 表示输入的值， a 表示一个可调节的超参数。当 x 大于 0 时，函数返回 x ；当 x 小于等于 0 时，函数返回一个非线性函数，这个函数的形状类似于 logistic 函数，但它的极限是 0 而不是 1。

FReLU 在分类、目标定位和语义分割任务上有了很大的改进，其重要原因是引入了多个可训练参数，提高了网络的自适应能力。其中，利用二维卷积捕获了复杂的二维空间信息，通过参数训练和迭代提高对隐藏信息的敏感性，以参数数量可以忽略的方式实现像素级网络建模。原理图如图 2.10 所示，其中卷积核的大小为 3×3 。




图 2.10 FReLU 原理

第三章 基于 ACU-Net 的医学超声图像分割

3.1 实验综述

超声图像是目前临床上最重要的成像方式之一。超声作为近年来迅速发展起来的一项技术，它具有无疼痛，无辐射，成本低，可实时成像等特点，但该方法目前仍有着成像质量差，差异大等缺点。在图像分析方面，非常有必要开发出一种先进的自动化的超声图像分析方法，来辅助医生进行超声诊断。一方面，它能够减轻医生的工作负担，另一方面，它还能够减少医生的主观性，从而使诊断变得更加客观和准确。深度学习是最近几年发展起来的一种重要的机器学习方法，在很多领域都得到了广泛的应用，特别是在图像分析和计算机视觉中。同时，深度学习技术也在超声影像处理领域展现出了广阔的应用前景。

在医学超声图像分割应用中，乳腺超声图像分割是发展较为快速的领域之一，同时也能够作为医学图像分割中的代表。本文将深度学习在乳腺超声图像中的分割应用为例，利用 IBreast Ultrasound Images(BUSI) 数据集进行实验，研究乳腺超声图像分割过程中的重难点，并探讨深度学习在医学超声图像分割中的联系与应用。

乳腺癌是全世界妇女最常见的恶性肿瘤之一，同时也是造成女性癌症死亡重要原因，对乳腺癌的早期发现有助于减少早期死亡人数^[13]。根据肿瘤研究机构的报告显示，如果被确诊为乳腺癌并得到正确的治疗，一般情况下是可以具有良好的预后^[14]。实际上，如果能在乳腺癌的早期被诊断治疗，治疗效果会更好，生存率甚至可以达到 90%以上^[15]。因此，利用计算机辅助诊断系统在临床上快速诊断病人是否患有乳腺癌变得极为重要。乳房超声图像与深度学习相结合，可以在乳腺癌的分类、检测和分割方面取得很好的效果^[16]。

3.2 实验数据集预处理

3.2.1 数据集介绍

本实验采用的 BUSI 数据集为乳腺癌超声扫描的医学影像。这些乳房超声数据集被分为三类：正常、良性和恶性图像。该数据集由 Aly Fahmy 等人于 2018 年收集，其中包含了 25-75 岁妇女的 780 张乳腺超声图像，其中患者人数为 600 人。数据集包括正常图片 133 张，良性肿瘤图片 210 张，以及恶性肿瘤图片 437 张。超声图像的平均尺寸为 500*500 像素，图片格式为 PNG。扫描过程中使用

的仪器是通常用于在放射学、心脏和血管应用中的顶级成像的 LOGIQ E9 超声系统和 LOGIQ E9 Agile 超声系统。其中真实图像与原始图像一起呈现，原始图像包含不用于大规模分类的不重要信息。

为了能让该数据集在我们的实验中更好地使用，我们应当对数据集进行一定的预处理，将获得的图像信息变成统一的规格，同时解决样本不均衡的问题。预处理包括删除重复的图像、数据增强等。

3.2.2 数据集预处理

本次实验使用数据增强来扩充数据集。由于深度学习分类的准确性对数据量的要求很高，数据量越充足，网络越深其性能则越好，但是医学超声图像往往由于病人隐私等各种原因，数据集的图像不够进行大规模训练，且如果想要从其它渠道获得更多的图片数据可能会耗费大量时间与资源。因此，我们需要对有限的数据集进行扩充，从而获得更多的数据量以供训练，即数据增强。数据增强通过把已有的数据进行翻转、旋转、缩放等一系列操作，扩展出更多的数据。如图 3.1 所示，通过对原图进行 90° 和 180° 的旋转以及水平和垂直翻转，将一张图片扩展成为了五张图片的数据量。




图 3.1 数据集扩充示例

3.3 实验

3.3.1 实验简介

本次实验用到了消融实验。消融实验是常用于神经网络中用于验证某一模块的效果所进行的实验，该实验类似于控制变量方法，通过引入或消除一个或多个模块，并与原始实验数据进行对比，以研究该模块是否能够有效提升性能。

本次实验共分为三部分，第一部分为对比经典 U-Net 模型在不同下采样次数和通道数情况下的性能表现；第二部分将引入 SE-Net 模块和 FReLU 函数与引入前进行对比，以验证它们是否能带来更好的效果；第三部分通过比较不同的膨胀率，从中得出 3 个最佳的膨胀系数。

本次实验采用的硬件配置及开发环境如表格 3.1 所示。

表 3.1 硬件配置及开发环境

硬/软件名称	硬/软件型号
CPU	INTEL i5-9300
GPU	NVIDIA GTX1650
内存	16 GB
CUDA	12.0
操作系统	Windows 10
实验环境	Pytorch
编程语言	Python 3.9

3.3.2 损失函数

本实验采用的损失函数为 BCE + Dice Loss，BCE 即二分类交叉熵，常用于二分类任务中，它的作用比较模型预测值与真实值的差异，BCE 的值越小则代表模型预测效果越好。Dice 系数是用来度量集合相似度的函数，通常用于计算两个样本之间的像素相似度。BCE 与 Dice Loss 搭配使用，互相补充，BCE 能够在像素上进行拉近，Dice Loss 则从全局进行考察。该模型的公式如下所示，其中 $p(x)$ 为模型预测的前景概率， y 是真实标签。

$$BCE = -(y \log(p(x)) + (1 - y) \log(1 - p(x))) \quad (3-1)$$

$$Dice\ Loss = 1 - Dice\ coefficient \quad (3-2)$$

3.3.3 评价指标

在语义分割中，真阳性（True Positive，TP），代表预测为 1，真实为 1。假阴性（False Negative，FN），代表预测为 0，真实为 1。假阳性（False Positive，FP），代表预测为 1，真实为 0。真阴性（True Negative，TN），代表预测为 0，真实为 0。

在本次实验中，我引入了四项指标作为分割实验结果的评价指标，分别为 Dice 系数（Dice coefficient）、敏感度（Sensitivity）、特异度（Specificity）和准确率（Accuracy）。其中敏感度指的是所有真实乳腺癌案例中被判断为乳腺癌的比例，与召回率（Recall）相同，即 TP 在所有预测值中的比例。敏感度越高意味着漏诊率越低，分割效果越好。

$$Sensitivity = \frac{TP}{TP+FN} \quad (3-3)$$

特异度指的是所有真实非乳腺癌案例中被判断为非乳腺癌的比例，即 TN 在所有真实值中的比例。特异度越高说明误诊率越低，分割效果越好。

$$Specificity = \frac{TN}{TN+FP} \quad (3-4)$$

准确率指的是本实验中所有真实乳腺癌案例中被判断为乳腺癌以及所有真实非乳腺癌案例中被判断为非乳腺癌的数量，在所有预测值与真实值中的比例。换句话说，就是模型预测正确的数量占总样本的比例，即 TP+TN 在总样本之中的比例。准确率越高代表分割效果越好。

$$Accuracy = \frac{TP+TN}{TP+FN+TN+FP} \quad (3-5)$$

最后我们使用 Dice 系数来判断该模型的性能。Dice 系数计算的是真实肿瘤出现的区域与模型预测肿瘤出现的区域之间的相似度，其与 F1_Score 相同，范围在 0 到 1 之间。本文将 Dice 系数化为百分数，Dice 系数越高意味着分割效果越好。

$$Dice = \frac{2TP}{2TP+FP+FN} \quad (3-6)$$

3.3.4 实验结果

为了体现出引入 SE-Net 模块和 Frelu 函数后模型获得的改进，反映出 ACU-Net 与传统 U-Net 模型相比的性能表现，本实验使用了语义分割中的经典模型 U-Net 以及本文关注的 ACU-Net 模型进行消融实验，希望能从中看出 ACU-Net 模型所带来的性能提升。

第一部分实验是对比 U-Net 模型在具有不同下采样次数和最大通道数情况下的性能表现。实验结果如表格 3.2 所示，在 Model 一栏下，U-Net(a,b)中的 a 代表除网络输入部分外的总下采样次数，b 代表最大通道数。不同的组合会导致模型大小和性能的差异。

表 3.2 具有不同下采样次数和通道数的 U-Net 性能表现

Model	Dice (%)	Sensitivity (%)	Specificity (%)	Accuracy (%)
U-Net (4, 1024)	78.54	79.57	99.45	98.67
U-Net (4, 512)	78.69	75.53	99.64	98.65
U-Net (4, 256)	75.43	74.34	99.32	98.63
U-Net (3, 128)	69.54	77.64	98.85	98.32
U-Net (3, 64)	66.45	75.42	99.45	98.34

实验结果表明，当模型为 U-Net (4, 512)，即下采样次数为 4，最大通道数为 512 时，该模型拥有最好的性能。其敏感度为 75.53%，意味着有超过七成的肿瘤被检测出来。特异性为 99.64%，代表其误诊率仅不到 0.5%。同时准确率为 98.65%，Dice 系数为 78.69%。该模型的性能良好，并有着比 U-Net (4, 1024) 更小的体积，说明 U-Net (4, 512) 为当前情况下的最优解。该部分实验中 U-Net 的平均 Dice 系数为 73.73%。

第二部分实验是在下采样次数为 4 和最大通道数为 512 的情况下，将经典 U-Net 模型的激活函数 relu 替换为 Frelu 的前后性能对比，以及 ACU-Net 模型替换 Frelu 函数和 SE-Net 模块的前后性能对比。实验结果如表格 3.3 所示，其中 Rates 代表膨胀率。

表 3.3 替换 Frelu 与添加 SE 前后性能对比

Model	Dice (%)	Sensitivity (%)	Specificity (%)	Accuracy (%)
-------	----------	-----------------	-----------------	--------------

U-Net (4, 512)	78.69	75.53	99.64	98.65
U-Net (4, 512)+FReLU	78.92	75.65	99.45	98.23
ACU-Net (4, 512)Rates (1, 4, 8)	75.54	77.12	98.53	98.64
ACU-Net (4, 512)Rates (1, 4, 8)+FReLU	75.66	76.32	99.45	99.43
ACU-Net (4, 512)Rates (1, 4, 8)+FReLU+SE	76.45	77.32	99.46	99.74
ACU-Net (4, 512)Rates (1, 6, 12)	79.45	75.97	99.64	98.34
ACU-Net (4, 512)Rates (1, 6, 12)+FReLU	80.45	77.67	99.54	99.62
ACU-Net (4, 512)Rates (1, 6, 12)+FReLU+SE	82.45	79.42	99.6	99.8

从实验数据可以看出，ACU-Net 在膨胀率为(1, 4, 8)情况下，无论是否引入 FReLU 函数和 SE-Net 模块性能都不如经典 U-Net 模型；而在膨胀率为(1, 6, 12)的情况下，总体性能对比经典 U-Net 模型都有一定的提升。从消融实验来看，U-Net 模型在引入 FReLU 函数前后性能并没有明显的变化；ACU-Net 在不引入模块和使用原本 relu 函数情况下的平均 Dice 系数为 77.49%，在将 relu 函数替换为 FReLU 函数后的平均 Dice 系数为 78.05%，同时引入注意力模块后的平均 Dice 系数为 79.45%。从实验数据可以看出 ACU-Net 在替换 FReLU 函数后性能有一定的提升，并在引入 SE-Net 模块后有着进一步的提高。这意味着 FReLU 激活函数和注意力模块对于 ACU-Net 模型的性能提高都有帮助。ACU-Net(4, 512)在膨胀率为(1, 6, 12)时引入 FReLU 函数和 SE-Net 模块能达到最好的分割效果，其 Dice 系数为 82.45%，敏感度为 79.42%，均比单独使用 U-Net 模型高了约 4 个百分点。同时特异性为 99.6%，准确率为 99.8%。

为了方便地看出模型之间的分割性能差异，本文将实验结果进行了可视化，并选取一些样本进行对比。如图 3.2 所示，第一行为良性肿瘤图片，第二行为恶性肿瘤图片；各列分别为原图、真实值、U-Net 分割结果和 ACU-Net 分割结果。




图 3.2 分割结果可视化

由于第一行是良性的，良性的病灶部分比较规整，所以分割出来的效果各个模型都是不错的。第二行是恶性的，从图里可以明显看出 ACU-Net 模型是优于 U-Net 的，并且更加接近真实值。

第三部分实验是在 ACU-Net (4, 512) 替换了 Frelu 函数和引入注意力模块后，研究其 ASPP 模块中不同膨胀率对分割性能的影响。本实验共研究了 12 种不同的膨胀率组合，实验结果如表格 3.4 所示。

表 3.4 不同膨胀率对 ACU-Net 分割性能影响

Model	Dice (%)	Sensitivity (%)	Specificity (%)	Accuracy (%)
ACU-Net (4, 512) Rates (1, 4, 4)+FReLU+SE	71.54	77.12	98.53	98.64
ACU-Net (4, 512) Rates (1, 4, 8)+FReLU+SE	76.45	75.97	99.64	98.34
ACU-Net (4, 512) Rates (1, 4, 12)+FReLU+SE	75.66	76.32	99.45	99.43
ACU-Net (4, 512) Rates (1, 5, 4)+FReLU+SE	71.9	77.67	99.54	99.62
ACU-Net (4, 512) Rates (1, 5, 8)+FReLU+SE	76.46	76.32	99.45	99.43
ACU-Net (4, 512) Rates (1, 5, 12)+FReLU+SE	77.88	77.67	99.54	99.62
ACU-Net (4, 512) Rates (1, 6, 4)+FReLU+SE	73.75	77.32	99.46	99.74
ACU-Net (4, 512) Rates (1, 6, 8)+FReLU+SE	78.9	78.35	99.54	99.78
ACU-Net (4, 512) Rates (1, 6, 12)+FReLU+SE	82.45	79.42	99.6	99.8
ACU-Net (4, 512) Rates (1, 8, 4)+FReLU+SE	77.69	75.53	99.64	98.65
ACU-Net (4, 512) Rates (1, 8, 8)+FReLU+SE	78.54	75.53	99.64	98.65
ACU-Net (4, 512) Rates (1, 8, 12)+FReLU+SE	78.92	75.65	99.45	98.23

实验显示，膨胀率并不是越大越好，较大的膨胀率会导致模型漏掉一些小物体的细节，使模型难以对这些细节进行分割，因此需要灵活调整膨胀率的组合，使性能最大化。由实验结果看来，当模型为 ACU-Net (4, 512) 并引入 Frelu 函数和注意力模块时，膨胀率 (1, 6, 12) 具有最好的性能，其性能指标与第二部分实验中相同。该部分实验中 ACU-Net 的平均 Dice 系数为 76.67%。

综上所述，本次实验中拥有最好性能的分割模型为 ACU-Net (4, 512) Rates (1, 6, 12)+Frelu+SE。其 Dice 系数为 82.45%，漏诊率为 20% 左右，误诊率为 0.4%，准确率高达 99.8%。ACU-Net 模型的性能相较于经典 U-Net 模型有较大的提升，其引入的 ASPP 模块、注意力模块和 Frelu 函数都对其性能有着一定的增强作用。ACU-Net 在乳腺超声图像分割中有着较好的表现，有望投入到医学超声图像分割应用中。

第四章 总结与展望

4.1 全文总结

最近几年,由于生活习惯和社会压力的增加,各种疾病给人们的生活带来了很大的影响,我国一线城市肿瘤发病率已经与欧美等发达国家相当,且呈年轻化趋势。为了做到尽早筛查以及尽早治疗,需要发展计算机辅助诊断系统(CAD),以提高医生工作效率。深度学习作为机器学习分支得到了快速发展,其具有强大的性能和端到端的便捷性等特点,已经在很多领域得到了广泛应用,尤其是在超声图像分割领域。超声图像是临床上最重要的成像方式之一,在医学超声图像分割应用中,乳腺超声图像分割能够作为医学图像分割中的代表。本文利用深度学习实现医学超声图像的自动分割,研究 ACU-Net 模型在乳腺超声图像中的分割应用。乳腺癌是全世界妇女最常见的恶性肿瘤之一,因此利用计算机辅助诊断系统在临床上快速诊断病人是否患有乳腺癌变得极为重要。超声图像与深度学习相结合可以在癌症等多种医学领域的分类、检测和分割方面取得很好的效果。

本文重点关注了一种对经典 U-Net 进行改进的模型,即 ACU-Net,它利用空洞卷积提高感受野和细节捕获能力,使用轻量级 ASPP 模块代替 U-Net 特征提取部分的两层连续卷积,保留原有 U-Net 结构的对称 U 型结构,并将激活函数替换为 FReLU 同时增加注意模块,有效提升了分割性能。在本次实验中我们使用的数据集为 BUSI,并对其进行了数据增强处理以扩充数据集的大小。在对模型进行评价时,主要以四个指标来评价分割性能,分别为 Dice 系数、敏感度、特异度和准确率。实验表明,ACU-Net 网络能在更小的体积下,通过改变激活函数并加入 SE-Net 模块,出色地完成了超声图像分割任务,达到甚至超过 U-Net 的分割效果,并具有更好的分割性能和能效比。消融实验同时表明替换激活函数为 FReLU 以及加入注意力模块都对 ACU-Net 的性能有一定的提高,而当 ASPP 模块中的膨胀率为(1, 6, 12)时该模型具备最好的分割性能。这些实验结果都证明了 ACU-Net 结构的有效性,以及它在乳腺超声图像分割任务中的信息捕获能力和较强的适应性,希望能给医学超声图像分割领域乃至计算机辅助系统提供一个不错的参考方案。

4.2 研究展望

本文在之前的理论基础上,将 ACU-Net 模型与传统 U-Net 模型进行对比,

体现出 ACU-Net 在医学超声图像分割领域的优势，并对该模型有了较为深刻的了解。此外，由于时间和精力有限，实验仍具备一些可以改进的地方，例如本次实验的数据集较为单一，仅采用了 BUSI，同时样本数也不够充足，希望后续能够获取更多的样本来进行更加充分的实验。

目前，已有越来越多的深度学习模型在医学超声图像分割领域准备投入应用，例如 3D 超声图像分析已经在基于超声的临床应用中显示出巨大的潜力，未来一定有更多新颖的深度学习算法将被开发，以更高的性能来解决医学超声图像分析中的各种任务。人们对于深度学习以及超声图像分割的探索仍在不断地进行中，相信在未来这些技术一定能够为人类医学水平带来巨大进步。

参考文献

- [1] 世界卫生组织发布《关于老龄化与健康的全球报告》[J]. 中国卫生政策研究, 2015
- [2] 赵曼雪. 基于超声图像的乳腺肿瘤自动分割技术研究[D]. 南京邮电大学, 2021
- [3] Yoon W B, Ji E O, Chae E Y, et al. Automatic Detection of Pectoral Muscle Region for Computer-Aided Diagnosis Using MIAS Mammograms[J]. Biomed Research International, 2016
- [4] Long J, Shelhamer E, Darrell T. Fully Convolutional Networks for Semantic Segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015
- [5] Shen D, Wu G, Suk H-I. Deep learning in medical image analysis[J]. Annual review of biomedical engineering, 2017
- [6] 许春波. 基于深度学习的乳腺异常分类和肿块检测及分割[D]. 兰州大学, 2022
- [7] Oktay O, Schlemper J, Folgoc L L, et al. Attention U-Net: Learning Where to Look for the Pancreas[J]. 2018.
- [8] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//International Conference on Medical image computing and computer-assisted intervention. 2015
- [9] 杨洋. 基于全卷积神经网络的乳腺钼靶 X 线全图像肿块分割研究[D]. 兰州大学, 2021
- [10] Jianfeng Li, Zhenghong Huang, Yongling Wang, Qinghua Luo. Sea and Land Segmentation of Optical Remote Sensing Images Based on U-Net Optimization[J]. 2022
- [11] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, Hartwig Adam. Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation[J]. 2018
- [12] Ningning Ma, Xiangyu Zhang, Jian Sun. Funnel Activation for Visual Recognition[J]. 2020
- [13] Jemal A, Siegel R, Xu J, et al. Cancer Statistics, 2010[J]. Ca A Cancer Journal for Clinicians, 2010
- [14] Kaul K, Daguilh F M. Early Detection of Breast Cancer: Is Mammography Enough[J]. Hospital Physician, 2002
- [15] 武志岗. 乳腺良恶性肿瘤的超声诊断价值分析[J]. 中国医药指南, 2016
- [16] Horsch K, Giger M L, Venta L A, et al. Computerized Diagnosis of Breast Lesions on Ultrasound[J]. Medical Physics, 2002

致 谢

时光飞逝，转眼间兰州大学的四年时光已经接近尾声，虽然由于疫情等原因，大学四年时光和我想象中不太一样，但它依然成为了我的生命中的一道亮丽的风景线。在这些年里，学习生活作为主旋律，其中穿插了许多和老师同学们的快乐经历，这些都构成了我对兰州大学的美好回忆。四年前青涩无知的我站在兰州大学的校门前，对即将到来的大学时光满怀期待；如今的我已经拥有了充足的知识储备和阅历，并在兰州大学“自强不息，独树一帜”的校训引导下形成了一套完善的人生观和世界观，这使我对母校充满了不舍与感激。

在此，首先要感谢我的指导老师马义德，他在论文的选题和修订过程中给予了我很多宝贵的建议，同时也在我的升学过程中给了我许多鼓励。本次论文是我初次接触医学图像分割内容，学习过程中我掌握了许多深度学习与图像分割相关的知识，为我将来的学习铺好了道路，十分感谢马老师愿在百忙之中做我的引路人。祝愿马老师身体健康、工作顺利。

其次要感谢姚子欢学长对于我论文的研究方向、实验过程及数据上的指导与建议，对于我所提出的问题非常耐心地指教，引导我学习了 pytorch 及语义分割相关内容，在我撰写毕业论文的过程中提供了非常大的帮助，并最终完成了论文目标。衷心希望学长能够在他的研究领域中取得成功。

另外，我还要感谢我的三位室友们，他们陪伴着我度过了大学四年，我们彼此鼓励，彼此扶持，无论在学习还是在生活中，我都离不开他们的关照。祝愿我们都能有一个美好的未来。

再者，感谢我的家人一直以来对我无条件的关爱与鼓励，是你们的爱让我在失落的时候重拾信心，更加勇敢地走下去，我一定不会辜负你们的期望。

最后，感谢培育我的兰州大学，以及信息科学与工程学院的所有老师们，感谢你们对我的教诲，是你们让我感受到了校园生活的美丽。在未来的学习道路上，我也会将你们铭记于心。

导师评语

论文主要对 ACU-Net 模型进行研究,并将其应用于 BUSI 乳腺超声图像数据集上进行分割性能评估实验,验证了 Frelu 激活函数和注意力模块对于 ACU-Net 分割性能所带来的提升,同时找到了最佳的膨胀系数并得到最佳分割模型,体现了 ACU-Net 模型在医学超声图像分割中的良好性能。

建议成绩 优秀 指导教师 (签字) _____

该生做了毕业论文陈述，并回答了相关问题。经全体答辩委员会成员讨论后一致决定，其答辩成绩评定为优秀。

答辩委员会负责人 (签字)

成绩 优秀 学院 (盖章) _____

年 月 日